

# Classificazione Multiclasse dell'Alzheimer Basata su Reti Neurali Convoluzionali Profonde

Annarita Bruno  
*Studentessa del corso di studi triennale  
in Informatica, Uniba*  
Bari, Italia  
a.bruno113@studenti.uniba.it

Giovanni Cirigliano  
*Studente del corso di studi triennale  
in Informatica, Uniba*  
Bari, Italia  
g.cirigliano5@studenti.uniba.it

## I. INTRODUZIONE

L'Alzheimer (AD) è una patologia neurodegenerativa progressiva che provoca una compromissione graduale e irreversibile delle funzioni cognitive. I pazienti affetti da Alzheimer sperimentano un declino costante delle capacità mnemoniche, cognitive e comportamentali. Questo deterioramento compromette progressivamente le abilità sociali e rende sempre più difficile svolgere le normali attività quotidiane, con un impatto devastante sulla qualità della vita e sull'autonomia personale.

Il rischio di sviluppare l'Alzheimer aumenta notevolmente con l'età, soprattutto dopo i 65 anni. Altri fattori di rischio includono la predisposizione genetica, l'ipertensione, il diabete e l'obesità. Nel 2020, oltre 55 milioni di persone nel mondo soffrono di una forma di demenza, con circa il 60-70% dei casi attribuiti all'Alzheimer. Questo numero raddoppierà quasi ogni 20 anni, raggiungendo i 78 milioni nel 2030 e i 139 milioni nel 2050. Il tasso di mortalità è alto: la demenza è la settimana causa di morte nei paesi sviluppati (3° in Italia), con 1.95 milioni di decessi nel 2021 [1] (+100.1% dal 1990 [2]) a livello globale e un'aspettativa media di vita dopo la diagnosi di circa 8-10 anni.

Nel 2019, la demenza ha comportato un costo globale di 1.3 trilioni di dollari, e si prevede che questo valore possa aumentare fino a 2,8 trilioni di dollari entro il 2030 a causa dell'invecchiamento della popolazione mondiale [3].

Nonostante decenni di ricerche, non è ancora disponibile una cura definitiva per l'Alzheimer. Pertanto, la diagnosi precoce rimane fondamentale per migliorare la qualità di vita dei pazienti e rallentare la progressione della malattia.

La diagnosi dell'Alzheimer si basa principalmente sul **neuroimaging clinico**, una branca della medicina che si concentra sull'uso di tecniche di imaging avanzate come la Risonanza Magnetica (MRI) per la diagnosi, la valutazione della progressione e il monitoraggio delle malattie neurologiche, tra cui l'Alzheimer. Grazie alla sua capacità di fornire immagini dettagliate e ad alto contrasto delle strutture cerebrali, la MRI è uno strumento fondamentale per rilevare i cambiamenti anatomici e funzionali associati all'Alzheimer.

In particolare, i cambiamenti cerebrali causati da Alzheimer e rilevabili con la MRI sono:

- **Atrofia dell'Ippocampo:** l'ippocampo, fondamentale per la memoria, è uno dei primi luoghi ad essere colpito. La MRI può mostrare una riduzione del suo volume, segnalando un possibile inizio della malattia.
- **Perdita di Volume Corticale:** la corteccia cerebrale, in particolare nei lobi temporali e parietali, si riduce con la progressione dell'Alzheimer. La MRI misura questa perdita di volume.
- **Ventricoli Cerebrali:** con la perdita di tessuto cerebrale, i ventricoli cerebrali si ingrandiscono. Questo fenomeno può essere rilevato dalla MRI indicando la presenza della malattia.

Dopo aver eseguito una MRI del cervello, le immagini ottenute vengono analizzate e confrontate con un dataset di normativi per rilevare eventuali anomalie indicative dell'Alzheimer.

Negli ultimi anni, il deep learning si è dimostrato uno strumento promettente per l'analisi di dati medici complessi, tra cui le immagini cerebrali. Il suo utilizzo permette di automatizzare l'analisi delle immagini MRI, riducendo la necessità di intervento manuale da parte di esperti radiologi. Questo non solo aumenta l'efficienza, ma riduce anche la possibilità di errori umani e variazioni nell'interpretazione. In particolare, le **Convolutional Neural Networks (CNN)**, un tipo di rete neurale profonda, sono state ampiamente utilizzate per riconoscere pattern complessi nelle immagini. Le CNN sono ispirate alla struttura e al funzionamento del cervello umano, organizzando l'analisi delle immagini in più strati gerarchici. I primi strati rilevano caratteristiche di base come bordi e angoli, mentre i livelli successivi combinano queste informazioni per identificare forme più complesse e, infine, oggetti o pattern più specifici.

Dopo aver definito l'architettura della CNN, sono state sperimentate tre diverse strategie di preparazione dei dati:

- 1) **Dataset non bilanciato** (Model 1), dove il modello è stato addestrato senza interventi per riequilibrare la distribuzione delle classi, consentendo di valutare come si comporta la CNN su un dataset disomogeneo.
- 2) **Train set bilanciato con Data Augmentation** (Model 2), dove sono state applicate tecniche di data augmentation per creare un training set bilanciato, aumentando

il numero di immagini delle classi meno rappresentate.

- 3) **Train, Validation e Test set bilanciati con Data Augmentation** (Model 3), in cui la bilanciatura è stata applicata non solo al training set, ma anche ai set di validation e test, garantendo una distribuzione uniforme delle classi in tutte le fasi dell'addestramento e della valutazione.

Queste tre varianti hanno permesso di valutare l'impatto della bilanciatura del dataset e dell'uso della data augmentation sulle performance del modello, con particolare attenzione all'accuratezza, alla capacità di generalizzazione e alla robustezza della CNN nel classificare correttamente le diverse categorie di Alzheimer.

## II. STATO DELL'ARTE

Negli ultimi anni, l'uso di tecniche di apprendimento profondo per la classificazione della malattia di Alzheimer ha registrato una crescita significativa, soprattutto grazie all'impiego di dati di imaging cerebrale multimodale. Diversi studi di ricerca hanno sviluppato varianti avanzate di reti neurali convoluzionali (CNN) per sfruttare la ricchezza informativa delle diverse modalità di imaging, migliorando l'accuratezza nella categorizzazione dell'Alzheimer.

Juan Song et al. [4] hanno esplorato l'uso di tecniche di deep learning, in particolare l'integrazione di immagini multimodali MRI e PET, per migliorare la diagnosi dell'Alzheimer. Uno studio di *Frontiers* ha presentato un metodo di fusione multimodale per combinare le informazioni strutturali delle immagini MRI con quelle funzionali delle immagini PET. Utilizzando questa combinazione, lo studio ha dimostrato che i modelli di deep learning, in particolare le CNN, possono identificare più accuratamente i segni precoci dell'Alzheimer rispetto all'uso di una singola modalità di imaging. L'integrazione delle due tecnologie ha portato a una migliore capacità di distinguere tra Alzheimer, lievi compromissioni cognitive (MCI) e soggetti sani, migliorando la precisione diagnostica.

Selehi et al. [5] hanno proposto una CNN per la diagnosi precoce e la classificazione dell'AD usando immagini MRI del dataset ADNI e viene evidenziato come l'utilizzo di una CNN e quindi del deep learning produca risultati migliori rispetto a quelli ottenuti usando algoritmi di machine learning, come Logistic Regression, Decision Tree, SVM, quando si lavora con grandi quantità di dati come i dati medici. Viene mostrato come per ogni fase è stato creato un piano di ricerca per soddisfare tutte le esigenze; tra le fasi troviamo: raccolta dei dati MRI, preparazione dei dati raccolti, training e testing. Tra i dati utilizzati troviamo immagini PET e MRI, test cognitivi, caratteristiche del sangue come predittori della malattia. La classificazione permetterà di dividere le informazioni in tre categorie: Mild, Normal Control e Alzheimer Disease. Per quanto riguarda il data processing, le immagini sono state convertite in formato jpg. Viene anche spiegato nel dettaglio l'architettura CNN implementata, che ha permesso di ottenere un 99% di Accuracy.

Odusami et al. [6] hanno proposto un metodo di deep learning per rilevare le fasi iniziali dell'Alzheimer (AD) utilizzando

una versione modificata del modello ResNet18 per estrarre le caratteristiche dalle immagini di neuroimaging ottenute tramite risonanza magnetica strutturale (sMRI). Lo studio ha preso in considerazione un totale di 413 soggetti, suddivisi in sei categorie: fase di salute normale, lieve compromissione cognitiva precoce, compromissione cognitiva lieve, ricordo notevole e Alzheimer. Il modello ottimizzato, basato su questa architettura CNN a 18 strati, ha raggiunto un'accuratezza del 99,09% nel distinguere tra le diverse categorie.

Pradhan et al. [7] hanno sviluppato un metodo per rilevare diversi stadi dell'Alzheimer (AD) utilizzando le architetture VGG19 e DenseNet169 per la classificazione. Il loro studio si basa su un dataset pubblico disponibile su Kaggle, che contiene 6000 immagini MRI etichettate in quattro categorie: AD lieve, moderato, molto lieve e non demente. Durante il processo di addestramento, l'80% delle immagini è stato utilizzato per l'apprendimento e il 20% per la validazione. VGG19, composta da circa 10-16 strati convoluzionali, ha dimostrato prestazioni superiori rispetto a DenseNet, raggiungendo un'accuratezza del 94%. DenseNet è stato impiegato per la classificazione delle immagini, ma VGG19 ha ottenuto risultati migliori in questo contesto.

## III. SOFTWARE E METODOLOGIA

### A. Software

Il sistema è stato sviluppato su Kaggle, una piattaforma di data science e machine learning che fornisce una vasta gamma di strumenti e risorse per progettare e addestrare modelli su dati complessi. Su Kaggle, abbiamo utilizzato un ambiente Jupyter Notebook all'interno di un ambiente virtuale che include una GPU NVIDIA Tesla P100 con 16 GB di memoria e una CPU Intel® Xeon® a 2,20 GHz con 4 core e 29 GB di RAM.

Le principali librerie utilizzate sono:

- *sklearn*: una libreria open source per l'apprendimento automatico, che fornisce strumenti efficienti per la costruzione e la valutazione dei modelli. Nel progetto, abbiamo utilizzato 'sklearn' per generare report di classificazione con metriche e per suddividere il dataset in set di addestramento, validazione e test.
- *tensorflow*: una delle librerie più rinomate per il deep learning, sviluppata da Google. Offre una vasta gamma di strumenti per costruire e addestrare modelli di machine learning.

### B. Data preparation

Prima di utilizzare le immagini nel processo di addestramento di una rete neurale convoluzionale (CNN), è fondamentale eseguire una preparazione accurata del dataset. Nel caso del dataset "Alzheimer's Dataset (4 class of Images)" disponibile su Kaggle, esso è composto da 6.400 immagini cerebrali in formato JPEG, con etichette che indicano la condizione del soggetto.

Queste immagini rappresentano scansioni MRI del cervello e sono caricate in scala di grigi, il che significa che ogni




Fig. 1. Grafico di distribuzione prima del bilanciamento

immagine ha un singolo canale di colore, riducendo la complessità computazionale rispetto alle immagini RGB.

Il dataset, già suddiviso in train e test set è stato riunificato e risuddiviso per ottenere una suddivisione più equa e per ricavare il validation set. In particolare:

- **Train set** (70% = 4480 img): utilizzato per addestrare il modello.
- **Validation set** (15% = 960 img): necessario per fornire un set di dati separato dal training set su cui il modello può essere valutato periodicamente durante la fase di addestramento. Questo permette di monitorare se il modello sta generalizzando bene o se sta semplicemente memorizzando i dati di addestramento (overfitting). Se durante l'addestramento il modello inizia a mostrare segni di overfitting (ad esempio, migliorando le prestazioni sul training set ma deteriorando quelle sul validation set), è possibile interrompere il processo (early stopping) ed adottare misure correttive come la regolazione degli iperparametri del modello o la modifica della sua architettura.
- **Test set** (15% = 960 img): riservato alla valutazione finale delle prestazioni del modello. Dopo il completamento dell'addestramento e la fase di ottimizzazione degli iperparametri, il test set viene utilizzato per fornire una misura imparziale della capacità di generalizzazione del modello addestrato. Esso consente di stimare con precisione come il modello si comporta su dati completamente nuovi e non visti precedentemente.

Per correggere lo squilibrio di classe presente nel dataset di immagini MRI (vedi Fig. 1), è essenziale implementare tecniche di Data Augmentation. Questo è fondamentale per migliorare la capacità di generalizzazione del modello, riducendo il rischio di overfitting verso le classi maggiormente rappresentate e migliorando le performance complessive del sistema di classificazione. Questo approccio viene adottato sia quando il Train Set è sottoposto a Data Augmentation (Model 2), sia quando l'intero set di Train/Test/Val è aumentato (Model 3).

Le immagini sono soggette a varie trasformazioni che

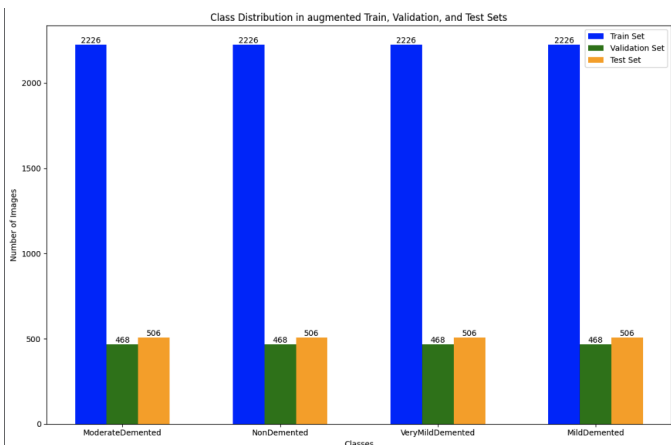


Fig. 2. Grafico di distribuzione dopo del bilanciamento

simulano differenti condizioni nelle immagini originali, aumentando così la variabilità del dataset senza aggiungere nuovi campioni. Queste operazioni includono:

- **Rotazioni:** le immagini vengono ruotate casualmente entro un intervallo di 10 gradi.
- **Zoom:** vengono effettuati zoom in e out sulle immagini con un intervallo del 10%.
- **Traslazioni orizzontali e verticali:** spostamenti lungo gli assi orizzontali e verticali fino al 5% dell'immagine.
- **Flip orizzontale:** inversione dell'immagine lungo l'asse orizzontale.

Dopo l'applicazione delle tecniche di **data augmentation**, i dati vengono normalizzati per migliorare la **stabilità** e l'**efficienza** del processo di addestramento del modello, soprattutto per le reti neurali convoluzionali (CNN). Questo passaggio è fondamentale per assicurare che il modello apprenda in modo ottimale senza oscillazioni nei valori dei pesi, che potrebbero altrimenti rallentare o compromettere la convergenza.

- 1) **Normalizzazione delle etichette (one-hot encoding):** Convertire le etichette delle classi in formato **one-hot encoded** consente al modello di trattare le classi in maniera binaria. Ogni classe è rappresentata come un vettore con un valore "1" nella posizione della classe corretta e "0" altrove. Questo formato è utile poiché permette alla rete di trattare la classificazione come un problema multi-classe, dove ogni neurone di uscita rappresenta una classe distinta.
- 2) **Riscalatura dei valori dei pixel:** Portare i valori dei pixel delle immagini all'interno di un range standard compreso tra 0 e 1 (invece del valore originale tra 0 e 255) stabilizza il processo di ottimizzazione. Riducendo i valori dei pixel a un intervallo ristretto, il modello evita aggiornamenti troppo grandi nei pesi, che potrebbero portare a instabilità nel gradiente e quindi a difficoltà di convergenza.

Successivamente, vengono creati generatori di dati che gestiscono in modo efficiente l'addestramento, la validazione




Fig. 3. Training set dopo augmentation

e il test del modello. I generatori utilizzano il meccanismo di mescolamento (shuffle) dei dati di addestramento e validazione, mentre i dati di test non vengono mescolati. Il motivo per cui si mescolano i dati di addestramento e validazione è quello di evitare che il modello si adatti (overfitting) a un ordine specifico delle immagini, consentendo una maggiore generalizzazione. Inoltre, il mescolamento riduce il rischio che il modello impari a riconoscere schemi non rilevanti dovuti all'ordine sequenziale dei dati, migliorando così la robustezza del processo di apprendimento.

Per quanto riguarda il test set, invece, i dati non vengono mescolati poiché lo scopo principale è valutare il modello su un insieme ben definito di dati che riflettono le condizioni reali, senza introdurre ulteriore casualità.

### C. Architettura CNN

Le Reti Neurali Convoluzionali (CNN) sono un tipo specifico di rete neurale artificiale, particolarmente efficace per l'elaborazione e l'analisi delle immagini. Sono strutturate in modo da simulare il funzionamento del cervello umano, in particolare la corteccia visiva, che è responsabile dell'elaborazione delle informazioni visive. Sono composte da diversi strati, ognuno dei quali esegue una specifica funzione per estrarre e apprendere caratteristiche dai dati in ingresso. L'architettura del modello CNN che proponiamo nel nostro studio è la seguente:

- **Strato/i di convoluzione:** è un'operazione matematica che permette di estrarre caratteristiche significative dalle immagini per la loro classificazione. Usano filtri (o kernel) per analizzare piccoli blocchi di pixel dell'immagine, calcolando prodotti scalari tra i valori del filtro e i pixel corrispondenti. Questo processo crea una "Feature Map", che rappresenta le caratteristiche rilevate. Questi strati riducono la complessità dell'immagine, concentrandosi su dettagli rilevanti e ignorando il rumore, e rendono la rete più efficiente e meno sensibile a variazioni come rotazioni e cambiamenti di illuminazione. Nel nostro modello ab-

biamo inserito tre blocchi convoluzionali Conv2D in cui aumentano man mano il numero di filtri (32 — 64 — 128) sempre di dimensione 3x3 per permettere al modello di apprendere una rappresentazione sempre più complessa delle caratteristiche. Agli strati convoluzionali abbiamo fornito come input un'immagine in scala di grigi di dimensioni 176x208 pixel. Viene applicata la funzione di attivazione ReLU (1) per introdurre non linearità nel modello, ed è definita come segue:

$$\text{ReLU} = f(x) = \max(0, x) \quad (1)$$

- **Strato/i di pooling:** è un'operazione da eseguire dopo la convoluzione, permette di ridurre le dimensioni delle feature map all'interno di una CNN mantenendo le caratteristiche più importanti. Viene utilizzato per semplificare le informazioni e ridurre il numero di parametri da gestire. Questo processo migliora l'efficienza computazionale e riduce la sensibilità a piccole variazioni o spostamenti nell'immagine. Dopo ogni strato di convoluzione abbiamo utilizzato il Max Pooling per ridurre le dimensioni della mappa di attivazione mantenendo le caratteristiche più salienti, mantenendo solo il valore massimo in ogni finestra 2x2, migliorando così l'efficienza e la robustezza del modello.
- **Strato/i Fully-Connected:** le mappe di attivazione vengono trasformate (Flatten) in vettori 1D che diventano input di una rete neurale densa (fully connected) composta da 512 neuroni usata per classificare le caratteristiche estratte dalle immagini. Anche qui viene utilizzata la funzione di attivazione ReLU(1) definita precedentemente per apprendere e rappresentare caratteristiche complesse. È stato anche aggiunto uno strato di Dropout con una probabilità di dropout del 50% (0.5). Durante l'addestramento, disattiva casualmente il 50% dei neuroni dello strato precedente. Questo aiuta a prevenire l'overfitting, forzando il modello a non dipendere eccessivamente da alcun neurone specifico e a generalizzare meglio ai dati di test.

**Output Layer:** un layer denso finale con neuroni pari al numero di classi e softmax come funzione di attivazione per la classificazione per produrre probabilità per ciascuna classe, definita come segue:

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_j e^{z_j}}$$

dove

- $z_i$  è l'elemento  $i$ -esimo del vettore di input  $z$
- $e$  è la base del logaritmo naturale (approssimativamente 2.718)
- la somma nel denominatore è fatta su tutti gli elementi del vettore  $z$

### D. Metriche di Valutazione Utilizzate

1. **Accuracy:** rappresenta la percentuale di previsioni corrette rispetto a tutte le previsioni effettuate. Generalmente, valori superiori all'80% sono considerati buoni, mentre valori

superiori al 90% sono eccellenti. Questa metrica è determinata dalla seguente espressione:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

dove:

- **TP (True Positive):** Questi sono i casi in cui il modello ha previsto correttamente una classe positiva (Ad esempio: paziente Mild Demented).
- **TN (True Negative):** Questi sono i casi in cui il modello ha previsto correttamente una classe negativa (Ad esempio: paziente Non Demented).
- **FP (False Positive):** Questi sono i casi in cui il modello ha previsto una classe positiva erroneamente.
- **FN (False Negative):** Questi sono i casi in cui il modello ha previsto una classe negativa erroneamente.

Nella figura 4-5-6, puoi osservare il grafico che traccia l'andamento dell'accuratezza durante le epoche di addestramento dei vari modelli. Questo grafico mostra chiaramente come le prestazioni del modello migliorano o peggiorano man mano che l'addestramento procede, consentendoci di valutare visivamente se e quando il modello inizia a sovradattarsi o a stabilizzarsi. L'accuratezza in relazione alle epoche ci fornisce informazioni cruciali sul comportamento del modello e su come risponde alle diverse tecniche di preparazione dei dati e di bilanciamento applicate.

**2. Precisione (Precision):** è definita come il rapporto tra le previsioni ottimistiche corrette e tutte le previsioni ottimistiche effettuate. Valori di precisione superiori all'80% sono generalmente considerati soddisfacenti. La precisione viene calcolata con la seguente equazione:

$$\text{Precision} = \frac{TP}{TP + FP}$$

**3. Richiamo (Recall):** conosciuto anche come tasso di sensibilità o tasso di veri positivi, il richiamo confronta le previsioni ottimistiche corrette con tutti i positivi effettivamente corretti. Valori accettabili di richiamo generalmente variano dal 70% al 90%. Il richiamo viene calcolato con la seguente formula:

$$\text{Recall} = \frac{TP}{TP + FN}$$

**4. F1-score:** è una metrica che combina precisione e richiamo, offrendo un valore univoco per ciascuna classe. Viene calcolato con la seguente formula:

$$\text{F1-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$




Fig. 4. Accuratezza durante il training del modello 1




Fig. 5. Accuratezza durante il training del modello 2

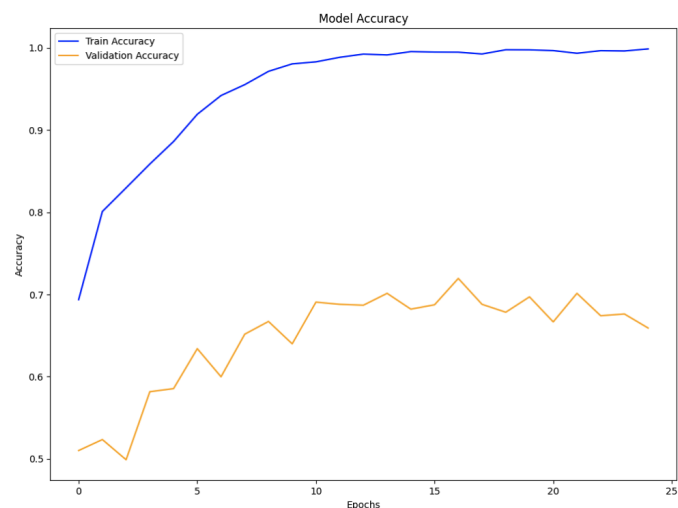


Fig. 6. Accuratezza durante il training del modello 3

## E. Training E Risultati

*Legenda delle Classi in cui classificare le immagini:*

- ModDem = ModerateDemented
- NonDem = NonDemented
- VeryMildDem = VeryMildDemented
- MildDem = MildDemented

(# : indica la cardinalità dell'insieme)

**1. Simple Training:** I dataset di input sono stati normalizzati e suddivisi in training, validation e test set, senza applicare alcuna tecnica di bilanciamento delle classi. L'obiettivo era verificare l'impatto del disequilibrio tra le classi sulle prestazioni del modello.

	ModDem	NonDem	VeryMildDem	MildDem
#TrainSet	41	2226	1573	640
#ValSet	9	468	362	121
#TestSet	14	506	305	135
Precision	0.00	0.53	0.00	0.15
Recall	0.00	0.94	0.00	0.07
F1-Score	0.00	0.68	0.00	0.09

TABLE I

CNN1 - SIMPLE TRAINING

	Cnn1
Epoche	25
LearningRate	1e-4
TestLoss	0.1229
TestAccuracy	97.71

TABLE II

CNN1 - SIMPLE TRAINING

**2. Training With Train Set Augmented:** Il modello presenta le stesse caratteristiche del modello 1 (Simple training), ma con l'aggiunta del bilanciamento delle classi nel training set, con l'obiettivo di valutare l'impatto di un equilibrio tra le classi sulle prestazioni del modello.

	ModDem	NonDem	VeryMildDem	MildDem
#TrainSet	2226	2226	2226	2226
#ValSet	9	468	362	121
#TestSet	14	506	305	135
Precision	1.00	0.98	0.99	0.97
Recall	1.00	0.99	0.97	0.97
F1-Score	1.00	0.99	0.98	0.97

TABLE III

CNN2 - TRAIN SET AUGMENTED

	Cnn2
Epoche	25
LearningRate	1e-4
TestLoss	0.0819
TestAccuracy	98.23

TABLE IV

CNN2 - TRAIN SET AUGMENTED

**3. Training With All Set Augmented:** 1 modello mantiene le stesse caratteristiche del modello 2 (Training With Train Set Augmented), ma include anche il bilanciamento delle classi nei set di validation e test, con l'obiettivo di verificare l'impatto di un equilibrio tra le classi su tutti i set di dati sulle prestazioni complessive del modello.

	ModDem	NonDem	VeryMildDem	MildDem
#TrainSet	2226	2226	2226	2226
#ValSet	468	468	468	468
#TestSet	506	506	506	506
Precision	0.01	0.60	0.24	0.02
Recall	0.00	0.92	0.20	0.02
F1-Score	0.00	0.73	0.22	0.02

TABLE V

CNN3 - ALL SET AUGMENTED

	Cnn3
Epoche	6(Early Stopping)
LearningRate	1e-4
TestLoss	2.0714
TestAccuracy	28.61

TABLE VI

CNN3 - ALL SET AUGMENTED

## IV. CONCLUSIONE E FUTURI SVILUPPI

Negli ultimi anni, la classificazione basata sul deep learning è stata ampiamente utilizzata per la diagnosi automatica dell'Alzheimer (AD) nelle sue fasi iniziali, impiegando tecniche basate sull'intelligenza artificiale per soddisfare gli obiettivi principali dei medici. In questo studio, abbiamo proposto un algoritmo di classificazione basato su reti neurali convoluzionali per l'Alzheimer utilizzando immagini MRI. Per ottimizzare le prestazioni del modello, sono stati esplorati tre diversi approcci di pre-processing dei dati progressivi: normalizzazione, bilanciamento del training set e bilanciamento esteso ai set di test e validation.

Dopo la fase di addestramento e validazione del modello, sono stati ottenuti i seguenti livelli di accuratezza: **97,71%** (Modello 1), **98,23%** (Modello 2) e **28,61%** (Modello 3). Tali risultati hanno evidenziato che il miglioramento più significativo si è ottenuto utilizzando il dataset con solo il Training Set aumentato, mentre Validation Set e Test Set rimangono invariati.

In futuro, il risultato potrebbe essere ulteriormente migliorato utilizzando un numero ancora più grande di MRI da combinare con altri biomarcatori (come PET scans, analisi del liquido cerebrospinale e dati genetici) per fornire una diagnosi più completa e precisa. Questa integrazione migliorerebbe di molto la capacità dell'algoritmo di identificare l'Alzheimer e monitorare la sua progressione.

## REFERENCES

- [1] Our World in Data. Deaths from Alzheimer's Disease. <https://ourworldindata.org/grapher/deaths-from-alzheimers>.
- [2] Alzheimer's disease: mortality trends. <https://pubmed.ncbi.nlm.nih.gov/34337138>.
- [3] World Health Organization. Dementia fact sheet. <https://www.who.int/news-room/fact-sheets/detail/dementia>.
- [4] J. Song et al., "Multimodal imaging-based Alzheimer's diagnosis using deep learning," *Frontiers in Digital Health*, <https://www.frontiersin.org/journals/digital-health/articles/10.3389/fdgth.2021.637386/full>.
- [5] Selehi et al., "Early Alzheimer's Disease Diagnosis Using CNN," *IEEE Access*, vol. 8, 2020. <https://ieeexplore.ieee.org/document/9215402>.
- [6] Odusami et al., "Diagnosis of Early-Stage Alzheimer's Using Modified ResNet18 on sMRI Data," *Diagnostics*, vol. 11, no. 6, 2021. <https://www.mdpi.com/2075-4418/11/6/1071>.

- [7] Pradhan et al., "Detection of Alzheimer's Disease in MRI Images Using Deep Learning," International Journal of Engineering Research Technology (IJERT), vol. 9, 2020. <https://www.ijert.org/detection-of-alzheimers-disease-ad-in-mri-images-using-deep-learning>.